

ANÁLISE DO ATRASO E DA BRECHA ACEITA DOS PEDESTRES EM TRAVESSIAS SEMAFORIZADAS: UM ESTUDO NA CIDADE DE FORTALEZA UTILIZANDO TÉCNICAS DE VISÃO COMPUTACIONAL BASEADAS EM *DEEP LEARNING*

Francisco Altanizio Batista de Castro Junior

Manoel Mendonça de Castro Neto

Flávio José Craveiro Cunto

Departamento de Engenharia de Transportes

Universidade Federal do Ceará

RESUMO

O aumento da atenção ao transporte ativo em países em desenvolvimento tem motivado estudos sobre compreensão dos fatores que afetam esses usuários. O atraso é um dos principais indicadores do nível de serviço de travessias de pedestres, e a duração da brecha aceita pelos pedestres está relacionada com os conflitos. Este trabalho visa relacionar atrasos e brechas aceitas em travessias semaforizadas de Fortaleza, além de comparar os atrasos coletados com os estimados pelo método do *Highway Capacity Manual* (HCM). Para realizar essa caracterização foram utilizados dados coletados por meio de visão computacional, em cinco travessias de interseções semaforizadas, obtendo-se 1642 observações. O método inclui uma análise de agrupamentos de pares de atraso e brecha aceita. Os resultados mostraram similaridade dos atrasos estimados com os do HCM, e as relações entre brecha aceita e atraso possibilitam uma caracterização da qualidade das travessias dos pedestres.

ABSTRACT

The increasing attention to active transport in developing countries has motivated research on understanding the factors that affect these users. Delay is one of the main indicators of the level of service at pedestrian crossings, and the duration of the accepted gap by pedestrians is related to conflicts. This paper aims to relate delay and accepted gaps at signalized intersections in Fortaleza and to compare the collected delays with those estimated by the Highway Capacity Manual - HCM method. We used data collected by computer vision on five signalized intersections, resulting in 1642 observations. The method includes a cluster analysis of delay and accepted gap pairs. The results showed similarity of the estimated delays with those from the HCM, and the relationship between delay and accepted gap provides a way to characterize the quality of pedestrian crossings.

1. INTRODUÇÃO

A implantação de interseções semaforizadas em corredores de transporte busca, entre outros aspectos, disciplinar os fluxos veiculares e minimizar os conflitos entre veículos e pedestres, sendo comum a adoção de estágios dedicados à travessia de pessoas. Entretanto, apesar dos benefícios *a priori* em segurança viária, a ocorrência de tempos de ciclo elevados e baixos tempos de verde efetivo para os pedestres tendem a elevar o atraso dos pedestres nessas travessias, impondo uma penalidade em tempo de viagem para esses usuários vulneráveis do sistema de transportes. Além disso, o atraso em interseções semaforizadas é um dos principais fatores apontados pela literatura que tendem a favorecer a ocorrência de travessias mais arriscadas (Jacobsen, 2011; Ma *et al.*, 2015).

Além de agravar os riscos de atropelamentos devido a travessias arriscadas, o atraso em interseções semaforizadas tende a diminuir os níveis de serviço dos pedestres e desfavorecer a atratividade dos modos ativos. Identificar pontos críticos de atraso para pedestres em trechos urbanos, com foco nas interseções semaforizadas, é essencial para melhorar as condições de segurança viária das cidades, prevenir conflitos veículo-pedestre e reduzir as impedâncias desse meio de transporte sustentável. Diante da multiplicidade de travessias em espaços urbanos e da elevada variabilidade dos fluxos de pedestres e veículos ao longo do dia, é desejável que se estabeleça um método de coleta que seja acessível, flexível, escalonável e preciso na estimativa dos indicadores coletados (Alver *et al.*, 2021; Zhang *et al.*, 2020).

Este trabalho possui três objetivos: o primeiro é apresentar um método de coleta e estimação dos atrasos e das brechas aceitas de pedestres em travessias semaforizadas, desenvolvido a partir de algoritmos de visão computacional, com as características desejadas anteriormente mencionadas. O segundo é comparar as estimativas de atraso com as estimadas pelo método do *Highway Capacity Manual* (HCM) (TRB, 2016). Por fim, o terceiro objetivo é investigar a relação entre os atrasos e as brechas aceitas; tal relação pode dar indícios do comportamento das travessias.

Para alcançar esses três objetivos, este trabalho está organizado em cinco seções, além da Introdução. Na Seção 2, apresenta-se uma síntese da revisão da literatura compreendendo os principais estudos sobre travessias de pedestres. Na Seção 3, apresentam-se os métodos de coleta propriamente dito, onde se descreve as estratégias adotadas para a estimação do atraso e da brecha aceita por meio de algoritmos de visão computacional. Na Seção 4, realiza-se uma aplicação do método para Fortaleza, utilizando de filmagens realizadas em câmeras de videomonitoramento do tráfego. Por fim, a Seção 5, traz as conclusões e recomendações para trabalhos futuros.

2. SÍNTESE DA REVISÃO DA LITERATURA

O atraso médio, definido como o tempo médio que os pedestres esperam para iniciar a travessia, é uma das principais medidas de desempenho de travessias de pedestres (TRB, 2016). Vários fatores podem influenciar o atraso, como o tempo de verde efetivo para os pedestres e a quantidade de travessias ocorridas durante o tempo de verde dos veículos, ou seja, durante o vermelho dos pedestres (Li *et al.*, 2005; Lipovac *et al.*, 2013; Martín *et al.*, 2019; Suh *et al.*, 2013; Tang *et al.*, 2020; Wang e Tian, 2010). Na literatura, essas travessias são comumente denominadas de *oportunistas* (Jacobsen, 2011; Liu *et al.*, 2000), mas no presente trabalho elas serão chamadas *travessias no vermelho*, quando possível.

Nesse contexto, diversos estudos buscam caracterizar os comportamentos das travessias de pedestres. Li *et al.* (2005) desenvolveram um método de estimação do atraso de pedestres em interseções semaforizadas na China e observaram uma variação substancial nos atrasos médios devido às travessias no vermelho. Wang e Tian (2010) abordam que a chegada de pelotões de pedestres influencia significativamente no atraso. Suh *et al.* (2013) observaram que o comportamento dos pedestres, como atraso e brecha aceita, tinham relação com o tempo de verde e o fluxo veicular. Lipovac *et al.* (2013) estudaram o comportamento do pedestre em travessias com exibidor de contagem regressiva e concluíram que nesses locais as travessias no vermelho eram, significativamente, menos frequentes. Mais recentemente, Tang *et al.* (2020) estudaram o comportamento de travessia em diferentes configurações de interseção e os resultados demonstraram que o aumento do ciclo semafórico aumentou o atraso dos pedestres em todas as configurações.

Martin *et al.* (2019) realizaram um estudo comparando o atraso do HCM e o estimado a partir de uma análise de simulação microscópica de tráfego, utilizando dados de travessias da cidade de Fortaleza. O estudo mostrou que quanto mais intensa a travessia no vermelho, mais o atraso se distanciava do estimado pelo HCM, visto que esse método não considera tal comportamento.

O método de estimação do atraso médio do HCM possui as seguintes premissas: i) o atraso médio é independente do volume de pedestres; ii) a chegada dos pedestres segue uma

distribuição uniforme; iii) todos os pedestres que esperam pelo sinal verde do pedestre iniciam a travessia simultaneamente; iv) os pedestres que chegam no intervalo verde para esse usuário atravessam à medida que chegam; e v) não é considerada a violação do semáforo (Martín *et al.*, 2019; Rouphail *et al.*, 1998; TRB, 2016). Tais premissas muitas vezes podem impossibilitar a sua aplicação em travessias típicas brasileiras, pois não representam de forma realística o comportamento desses usuários (Martín *et al.*, 2019). O valor do atraso médio dos pedestres (dp) é obtido no HCM pela Equação 1.

$$dp = (C - g + 4)^2 / 2C \quad (1)$$

Em que C é o tempo de ciclo total e g é o tempo de verde do pedestre. Observa-se que o método do HCM possui apenas dois dados de entrada, é, portanto, de simples aplicação.

Atualmente, diversos algoritmos e programas computacionais disponíveis propõem a utilização de Inteligência Artificial para realizar o rastreamento e a detecção de objetos em filmagens, para aplicações diversas. Em transportes, essa tecnologia permite, por exemplo, coletar dados em larga escala de fluxos de usuários motorizados e não-motorizados. Com os algoritmos atualmente disponíveis, os dados passíveis de serem coletados vão além dos fluxos, pois permitem obter as trajetórias detalhadas das pessoas e dos veículos ao longo do tempo (Alver *et al.*, 2021; Zhang *et al.*, 2020).

Nesse contexto, na última década surgiram estudos de travessias de pedestres que usaram visão computacional (Alver *et al.*, 2021; Zhang *et al.*, 2020). Alhajyaseen e Iryo-Asano (2017) verificaram a influência de diversos fatores, como a distância de travessia, na velocidade adotada pelos pedestres, por meio de processamento de imagem. Zhang *et al.* (2020) analisaram a intenção de travessia dos pedestres oportunistas e suas características, utilizando algoritmos de aprendizagem profunda (*deep learning*). E mais recentemente, Alver *et al.* (2021) aplicaram métodos de visão computacional para avaliar a brecha crítica aceita pelos pedestres em Esmirna, na Turquia.

3. MÉTODO ADOTADO

O método adotado neste trabalho consiste nas cinco etapas mostradas na Figura 1. Cada etapa será discutida nos cinco subitens desta seção.



Figura 1: Método empregado na pesquisa

3.1. Coleta e tratamentos dos dados

Os dados foram coletados a partir de uma análise de vídeos gravados por câmeras de videomonitoramento do Controle de Tráfego em Área de Fortaleza (CTAFOR) em dias úteis. Foram utilizadas cinco interseções semaforizadas, localizadas em áreas densas da cidade, com elevada concentração de pessoas devido à presença de atividade e de uso do solo comercial. Todas as filmagens foram obtidas durante o dia, buscando favorecer o rastreamento dos pedestres com imagens de melhor qualidade (luminosidade). Por fim, os dados obtidos foram tratados e analisados por meio de rotina computacional desenvolvida em linguagem R.

3.2. Pré-processamento dos vídeos

O pré-processamento consiste em uma série de atividades de tratamento dos vídeos: recorte dos trechos a serem analisados, conversão para um formato apropriado, redução das taxas de

captura de imagens em frames por segundo (*fps*) (foi adotado 10 *fps*) e hospedagem na plataforma dedicada do *Google* (*Google Drive*). A redução da cadência (*fps*) dos vídeos representa um equilíbrio entre a qualidade do processamento e o esforço computacional: quanto maior a taxa de *fps*, maior a qualidade e a precisão do rastreamento de objetos, entretanto maior o tempo de processamento.

3.3. Detecção e rastreio

O processamento de vídeos foi semelhante aos dos trabalhos de Alver *et al.* (2021) e de Zhang *et al.* (2020), baseado em três etapas: (i) o *YOLOv4* (Redmon e Farhadi, 2018; Bochkovskiy *et al.*, 2020; Wang *et al.*, 2021), algoritmo do estado da arte da Inteligência Artificial que permite a detecção de objetos em tempo real; (ii) *DeepSort* (Wojke e Bewley, 2018; Wojke *et al.*, 2017), um algoritmo de *deep learning* para rastreamento de objetos em vídeo; e (iii) *GoogleColab*, uma plataforma de desenvolvimento de linguagem Python na *nuvem*, que permite o processamento e a execução dos algoritmos com a disponibilidade de Placas de Vídeo (*GPUs*). O procedimento desenvolvido para este trabalho foi uma adaptação do código disponibilizado de forma livre no *GitHub* - *theAIGuysCode/yolov4-deepsort* (2020), a partir do qual foi realizada uma série de procedimentos em Python para coletar os fluxos, os atrasos e as brechas aceitas dos pedestres.

A detecção de objetos foi realizada com base no algoritmo *YOLOv4*, o qual consegue detectar 80 categorias de objetos com uma *Average Precision* (AP_{50}) de 65% no banco de dados *Common Objects in Context* (COCO) (Bochkovskiy *et al.*, 2020; Wang *et al.*, 2021). Além disso, Alver *et al.* (2021) verificou acertos acima de 95% na detecção de pedestres utilizando o *YOLOv3*. Nesta etapa, os fatores determinantes para a correta detecção e rastreamento dos objetos são a qualidade das imagens analisadas, a ausência de obstáculos ou objetos próximos que venham a gerar confusão na análise das imagens e o posicionamento das câmeras. Para verificar a precisão do algoritmo no cenário proposto, foi realizada, ao final, uma etapa de verificação de erros de detecção.

A Figura 2 ilustra o processo de detecção e rastreio, especificado para diferenciar pessoas, motocicletas, carros, ônibus e caminhões, identificados com quadrículas nos vídeos processados. Cada quadrícula (*bounding box*) é representada por um centroide, que é rastreado temporalmente, isto é, tem sua posição (relativa ao vídeo) monitorada ao longo do avanço temporal dos vídeos.

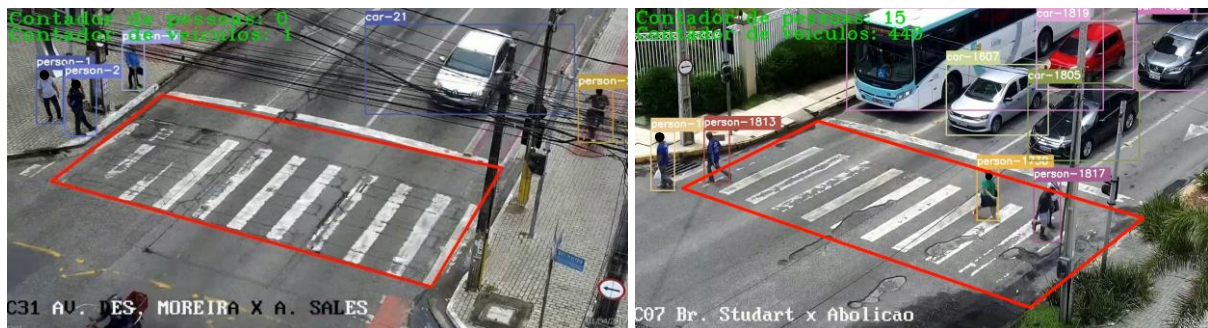


Figura 2: Exemplo da detecção e rastreio realizados

3.4. Estimação dos indicadores

O atraso dos pedestres foi definido, neste trabalho, como o intervalo de tempo entre o

aparecimento do pedestre no vídeo, isto é, a primeira detecção do pedestre no vídeo, e o início da travessia. Para tanto, foi definida uma fronteira (polígono em vermelho na Figura 2) que representa a zona de travessia: sempre que o centroide de um objeto da categoria *Pessoa* cruza o polígono pelas laterais (aresta adjacente à calçada), é contabilizado o instante de início de travessia e adicionada uma unidade ao contador de pessoas. Processo similar é feito com os automóveis, porém nas arestas voltadas às faixas de tráfego: sempre que um objeto da categoria *Carro*, *Motocicleta*, *Ônibus* ou *Caminhão* cruza a fronteira em vermelho, é contabilizado o tempo desse evento e, em seguida, é adicionado uma unidade ao contador de veículos. Reconhece-se, de forma preliminar, que a estimativa do atraso do pedestre a partir do aparecimento do mesmo no vídeo (e não da chegada no ponto de espera) pode, em alguns casos, superestimar os atrasos, o que depende, evidentemente, do grau de abertura das câmeras de videomonitoramento.

A brecha aceita pelos pedestres foi determinada como o intervalo de tempo entre os centroides de dois objetos da categoria veículo (*headway*), em qualquer faixa de tráfego, com referência ao momento de travessia, ou seja, no instante do cruzamento de um objeto da categoria *Pessoa* na fronteira de detecção (Alver *et al.*, 2021; Mohamad Nor *et al.*, 2017). Admite-se que a brecha aceita e o atraso estimados podem conter, em alguns casos, algum viés por conta de uma travessia interrompida. Em outras palavras, o centroide do pedestre cruza a linha de detecção, mas esse não realiza a travessia, esperando por outro momento.

Em resumo, a detecção e o rastreamento deste trabalho estimam: (i) os fluxos de pedestres e veículos temporalmente; (ii) os atrasos de pedestres; e (iii) as durações das brechas aceitas. Por fim, para medir a compatibilidade do método com o proposto pelo HCM foi realizada uma análise estatística das médias com intervalos de confiança de 95% de modo a comparar os resultados.

3.5. Relação entre os indicadores

Visando explorar a relação entre o atraso e a brecha aceita pelos pedestres, que pode dar indícios de características comportamentais das travessias, inicialmente, foi realizada uma análise visual com gráfico de dispersão e, em seguida, uma análise de agrupamento usando o método *k-means clustering*. O procedimento consiste, primeiramente, em *k* objetos escolhidos aleatoriamente, cada um representa um centroide de grupo. Em seguida, cada objeto restante é assimilado a um grupo, baseado na menor distância entre o objeto e o centroide do grupo. Finalmente, um novo centroide para cada grupo é computado e o processo é iterado até um ponto de parada (Forgy, 1965; Malki *et al.*, 2016). A escolha do número de grupos foi feita visualmente para cada interseção buscando encontrar interpretações sobre os pares de atraso e de brecha aceita dos pedestres nas travessias.

4. RESULTADOS

4.1. Travessias analisadas

A Tabela 1 mostra uma breve descrição dos cruzamentos analisados. Vale ressaltar que os dados dessa tabela foram obtidos do trabalho de Mesquita *et al.* (2020), o qual analisou o comportamento de travessia no vermelho nas mesmas interseções. Os tempos de ciclo semafórico foram obtidos por meio dos vídeos e verificou-se que apenas a C06 apresentou ciclo variável (diferença de 15 segundos), com variação de cerca de cinco segundos para o verde do pedestre.

O processamento envolveu cerca de 15 horas de vídeos, sendo aproximadamente três horas por local. Em se tratando de um algoritmo implementado em Python, essencialmente aberto, as restrições envolvidas no processo de tratamento estavam mais ligadas à plataforma utilizada para o processamento de vídeos (*GoogleColab*), que limitava a um máximo gratuito de 13h de uso de *GPUs*. Entretanto, esse tempo disponível mostrou-se suficiente para analisar os vídeos coletados. Foram coletadas 1642 observações e obtidos os fluxos, com base nos 15 minutos mais carregados, de pedestres (PPH) e veículos por hora (VPH) (Tabela 2).

Tabela 1: Características físicas dos cruzamentos. Fonte: Mesquita *et al.* (2020)

Código	Logradouro A	Logradouro B	Ciclofaixas	% Uso do solo não residencial	Faixas	Distância de Travessia (m)
C12	Av. Dom Luís	Av. Des. Moreira	Sim	86%	4	15,8
C06	Av. Dom Manuel	Av. Monsenhor Tabosa	Não	81%	3	17,5
C21	Av. da Universidade	Av. 13 de maio	Não	100%	4	17,5
C31	Av. Des. Moreira	Av. Antônio Sales	Sim	100%	3	12,5
C35	Av. da Abolição	Av. Barão de Studart	Não	82%	4	19

Tabela 2: Informações de controle semafórico e demanda dos cruzamentos

Local	Horário		Tempo de Ciclo (s)	g (s) pedestres	VPH	PPH	#N
	Início	Fim					
C06	01/04/2019 13:00	01/04/2019 16:05	128	73	1492	44	59
C35	03/04/2019 11:10	03/04/2019 14:09	127	73	1632	44	54
C21	29/03/2019 13:00	29/03/2019 16:00	145	99	1384	388	689
C31	01/04/2019 13:00	01/04/2019 16:00	128	62	1848	248	502
C12	03/04/2019 11:09	03/04/2019 14:09	145	65	2208	164	338

4.2. Indicadores estimados

Nesta subseção, por limitações de espaço, apresentam-se os resultados detalhados para uma das interseções, a C31 (Av. Antônio Sales x Av. Desembargador Moreira), pois é um cruzamento com fluxos elevados e configuração mais típica. Na Figura 3, apresenta-se a variação temporal do fluxo de pedestres na referida interseção, que mostra maiores fluxos de pedestres na pausa do almoço (próximo a 13h) e no final da tarde (próximo às 16h).




Figura 3: Variação temporal do fluxo de pedestres na travessia C31

A variação do tráfego veicular observado não demonstrou elevação de demanda nos períodos de pico. É possível entender que as taxas de fluxo relativamente constantes observadas em campo sejam reflexo de uma situação de saturação do sistema viário. Ao verificar o *headway* médio dos veículos, obtidos pelo tempo entre os centroides das quadrículas, observa-se valores

próximos a dois segundos e relativamente estáveis ao longo do dia (Figura 4).

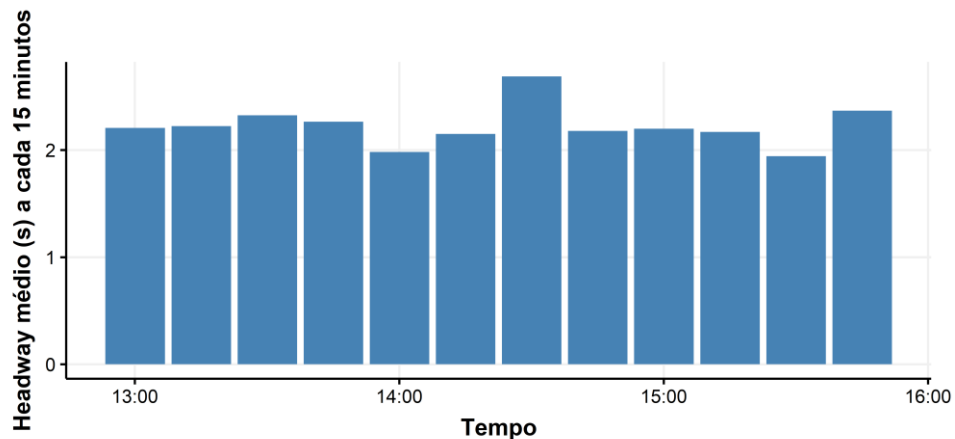


Figura 4: Variação do *headway* médio veicular na C31

Apresenta-se a seguir os resultados da estimação do atraso de pedestres na interseção. O histograma e o *boxplot* de atrasos (Figura 5) revela uma predominância de atrasos próximos de zero (s) na interseção, isto é, de pessoas que pouco esperam para realizar a travessia, o que ocorre no caso de pedestres que chegam na interseção no verde ou que chegam no vermelho, mas conseguem atravessar imediatamente.




Figura 5: Histograma e *boxplot* do atraso de pedestres na C31

Combinando os dados de intervalo de tempo entre veículos (*headway*) e os instantes de travessia dos pedestres, estimou-se a brecha aceita (Figura 6). Observam-se muitos valores próximos de zero. Tais valores podem ser devidos às travessias interrompidas, por falhas de detecção ou pela própria precisão temporal do método, que depende do *fps*. Com mediana de cerca de 30 segundos, as brechas aceitas pelos pedestres revelam elevada dispersão, o que deve ser consequência não somente da aleatoriedade de chegada dos pedestres na interseção, mas também da variedade de comportamentos de travessia.

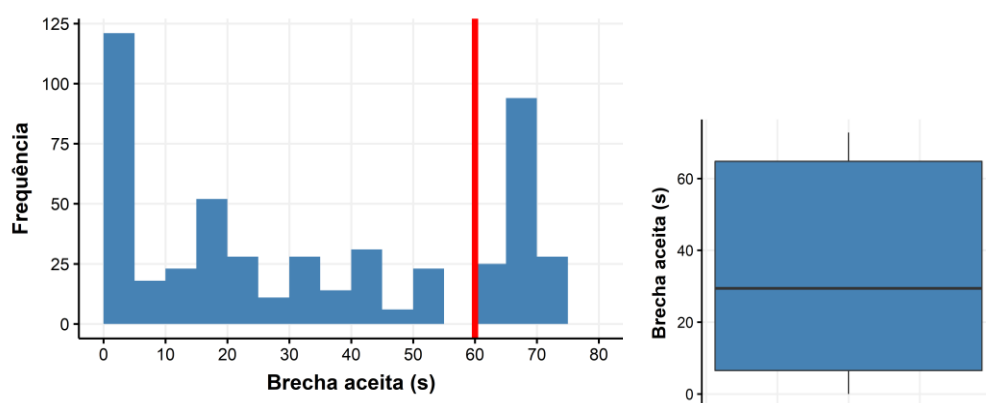


Figura 6: Histograma e *boxplot* da brecha aceita por pedestres na C31

Observa-se, na Figura 6, um *cluster* de brechas superiores a 60 segundos, separado pela linha vermelha vertical na figura. Assim, tendo em vista o ciclo semafórico da interseção em questão, as brechas aceitas superiores a 60 segundos são interpretadas como travessias potencialmente menos arriscadas. Ou seja, realizadas quando o semáforo estava vermelho para os carros ou o fluxo veicular era baixo o suficiente para ocasionar *headways* superiores a 60 segundos. Por outro lado, as brechas inferiores a 60 segundos podem ser interpretadas como travessias potencialmente arriscadas, pois o pedestre poderia estar em conflito com os veículos.

4.3. Comparação entre os indicadores estimados e o método do HCM

A Figura 7 compara os atrasos médios calculados pelo HCM com os atrasos estimados pelo método apresentado, com um intervalo de confiança (IC) de 95%. Devido à premissa de comportamento obediente, esperava-se que as estimativas de atraso do HCM fossem maiores que as do método empregado (Martín *et al.*, 2019; Suh *et al.*, 2013; X. Wang e Tian, 2010), entretanto observou-se que o valor está no intervalo de confiança na maioria das interseções. Ou seja, existe uma compatibilidade entre os valores obtidos dos dois métodos.

A interseção C21 apresenta características distintas em relação às outras, por exemplo, apresentando o menor valor de atraso calculado pelo HCM (6 segundos) e uma maior diferença ao estimado pelo método deste trabalho. Além disso, observa-se que nessa interseção é encontrado o maior tempo de verde e uma presença de um uso do solo primordialmente universitário, o que pode motivar travessias no vermelho (Suh *et al.*, 2013). Ademais, a C21 apresenta uma configuração viária (seção 4.5) que pode gerar algum erro nos atrasos estimados.

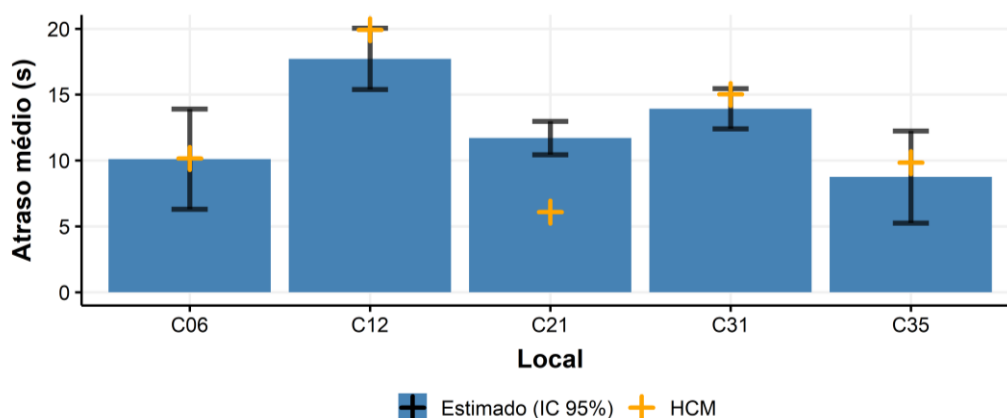


Figura 7: Comparação do atraso médio (com 95% de confiança) com o calculado pelo HCM

4.4. Relação entre atraso e brecha aceita dos pedestres

Visando explorar com maior profundidade a relação entre o atraso e a brecha aceita pelos pedestres, que pode dar indícios de características comportamentais das travessias, plotou-se as observações em um gráfico de dispersão. Observa-se que há uma clara separação entre as observações com brechas abaixo e acima de 60 segundos, o que é interpretado, como discutido anteriormente, como a fronteira do comportamento menos arriscada (à direita da linha vermelha) contra travessias potencialmente arriscadas (à esquerda da linha vermelha).

Apesar desse padrão nos dados, a fronteira do comportamento não é tão rígida. Assim, realizou-se uma análise de *k-means clustering* (Forgy, 1965), com quatro ou cinco grupos (Figura 8). É possível interpretar os grupos do lado direito (C e D) como grupos de pedestres com travessias menos arriscadas, sendo o grupo D com um maior atraso e o grupo C com um menor atraso.

Já os grupos A e B, por terem brechas aceitas inferiores aos prováveis tempos de vermelho veicular, são interpretados como travessias mais arriscadas, ou seja, grupos críticos, sendo o grupo B com um maior atraso e o grupo A com um menor. Por fim, o grupo E contempla os pedestres que aceitaram uma brecha relativamente suficiente para realizar uma travessia evitando um conflito mais grave com os veículos, pois acima de 20 segundo, em qualquer uma das cinco interseções, o pedestre teria uma velocidade média de 0,8 m/s, o que configura como uma travessia sem a necessidade de corrida (Alhajyaseen e Iryo-Asano, 2017; Alver *et al.*, 2021). Ressalta-se que os grupos E e B não foram observados em todas as interseções, necessitando alterar o número de grupos para se adequar com a caracterização proposta.

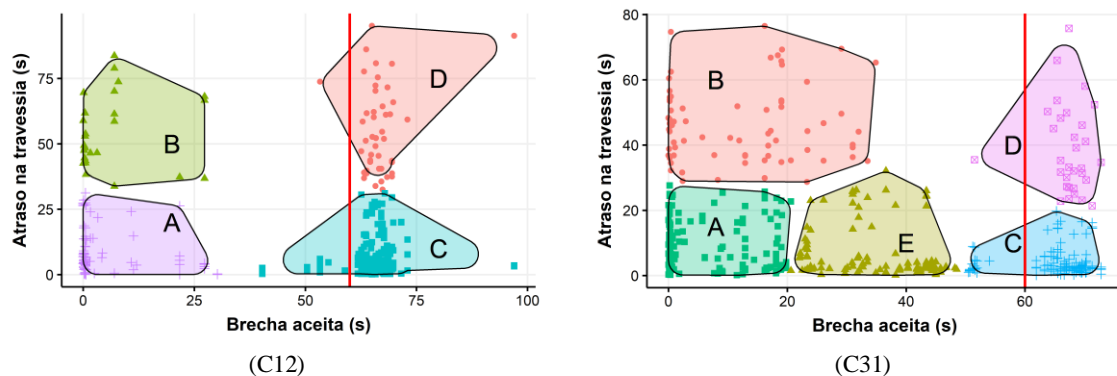


Figura 8: Análise de *clusters* de atraso da travessia e brecha aceita para a C12 e C31

A Tabela 3 mostra as porcentagens para os grupos críticos (A e B) para cada cruzamento, onde se esperava que as interseções com uma maior porcentagem nesses grupos apresentassem uma diferença maior entre os atrasos estimados e do HCM. Entretanto, observa-se que, em todas as interseções, existe uma porcentagem relevante de pedestres aceitando uma brecha curta (A e B) (em média 38%). Existem diversos fatores que podem estar influenciando nesse comportamento, como tempo de verde para os pedestres, uso do solo e fluxo veicular (Alver *et al.*, 2021; Mohamad Nor *et al.*, 2017; Suh *et al.*, 2013; Tang *et al.*, 2020).

Comparando dois locais com usos do solo semelhantes, um com menos porcentagem dos grupos A e B (C12) e outro com mais (C35), observa-se um fluxo veicular 35% maior no primeiro e um tempo de verde (pedestres) 12% maior no segundo. Pode-se levantar as hipóteses que um maior fluxo veicular tende a diminuir o número de brechas aceitáveis, portanto diminuindo os grupos A e B. Além disso, observa-se que a C35 tem um menor atraso, provavelmente devido ao maior tempo de verde e ao menor tempo de ciclo, como encontrado na revisão da literatura

(Suh *et al.*, 2013; Tang *et al.*, 2020). Nessa análise tentou-se controlar a influência do uso do solo comparando locais semelhantes, contudo é preciso analisar mais locais de modo a controlar de forma satisfatória as variáveis.

Com relação ao uso do solo, a C21 apresenta características distintas, sendo predominante um local educacional universitário, além de que o seu semáforo pode ser controlado pelo pedestre e apresenta o maior tempo de verde, garantindo um menor atraso para esse usuário. Portanto, observa-se que a C21 apresenta uma das menores proporções de pedestres com atraso elevado.

Tabela 3: Resumo das relações entre o atraso e brecha aceita pelos pedestres

Local	Atraso médio (s)				Brecha aceita média (s)				% na Área Crítica	
	Calculado				HCM				A	B
C06	10,1	IC [6,3	; 13,9]	10,2	67,3	IC [56,5 ; 78,2]	32%	-
C35	8,7	IC [5,2	; 12,2]	9,8	42,9	IC [31,0 ; 54,8]	52%	-
C21	11,7	IC [10,4	; 13,0]	6,1	56,3	IC [53,4 ; 59,2]	28%	6%
C31	13,9	IC [12,4	; 15,5]	15,0	32,9	IC [30,6 ; 35,3]	27%	14%
C12	17,7	IC [15,4	; 20,0]	19,9	46,4	IC [43,2 ; 49,5]	25%	8%

4.5. Possíveis erros de detecção

Alguns erros de detecção podem ocorrer com o algoritmo empregado. O primeiro diz respeito à classificação, que ocorre quando um objeto (pessoa ou veículo) é classificado erroneamente. Um segundo tipo de erro possível é a não-deteção (ver exemplos na Figura 9), que é mais frequente em situações em que há aglomerações de pessoas na travessia (a) ou onde há objetos que acabam confundindo a detecção de imagem (b).




Figura 9: Exemplos de erros possíveis de medição do algoritmo

O último tipo de erro discutido é retratado na Figura 9 (c), que apresenta a travessia do cruzamento C21; como a travessia é delimitada pelo retângulo vermelho, pedestres que aparecem, principalmente na parte esquerda da figura podem ter seu atraso superestimados, pois seu atraso começa a ser contabilizado a partir do surgimento no vídeo.

Visando estimar a magnitude dos erros de medição no algoritmo, realizou-se um processo de validação amostral, onde se tomou, para três dos locais de pesquisa, trechos de 30 minutos de vídeos, onde foram analisados os erros de detecção. As taxas de acerto, que correspondem à proporção de pedestres adequadamente classificados (tendo em vista o erro de classificação e a não-deteção) são apresentados na Tabela 4.

Tabela 4: Taxas de acerto de pedestres detectados por local de coleta

Código	Logradouro A	Logradouro B	Taxa de Acerto
C12	Av. Dom Luís	Av. Des. Moreira	85%
C31	Av. Des. Moreira	Av. Antônio Sales	95%
C35	Av. da Abolição	Av. Barão de Studart	67%

5. CONCLUSÕES E RECOMENDAÇÕES

A principal contribuição deste trabalho foi demonstrar a utilização de um método gratuito do estado da arte em visão computacional para obter automaticamente indicadores de desempenho operacional do sistema de tráfego. O método proposto, voltado para estimação de atrasos de pedestres, brechas aceitas e fluxo de veículos e pedestres, foi aplicado em cinco interseções semaforizadas de Fortaleza. A principal vantagem do método reside na rapidez e na praticidade da coleta automatizada, sem necessidade de computador pessoal próprio para o processamento, resultando em 1642 atrasos coletados que, caso coletados manualmente (em escritório, com análise de vídeo, ou em campo), exigiria custos consideráveis, bem como estaria sujeito a outros tipos de erros de coleta (Alver *et al.*, 2021).

A comparação com os valores estimados com o HCM aponta para uma convergência de resultados na maioria dos locais, apesar das limitações do método do HCM e do método deste trabalho. Por fim, a estimativa automatizada de brechas aceitas e a relação com o atraso permitiram a realização de análises de caráter comportamental dos pedestres quanto à travessia em cruzamentos com sinalização semafórica. Observou-se maior porcentagem de travessias menos arriscadas em interseções com maiores fluxos de pedestres e veículos, e verificaram-se menores atrasos dos pedestres em interseções com mais tempo de verde para esses usuários e menores ciclos semafóricos.

Como sugestão para trabalhos futuros, recomenda-se a realização de um refinamento nos critérios de identificação e rastreamento dos pedestres, buscando contabilizar o atraso somente a partir do instante que começa a espera, e não quando eles surgem no vídeo. Além disso, o ferramental pode ser adaptado para ter maior precisão em situações com angulações/qualidades de vídeo inferiores, bem como melhor lidar com a questão da identificação de pedestres em aglomeração.

Agradecimentos

O presente trabalho foi realizado com o apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001 e Conselho Nacional de Desenvolvimento Científico e Tecnológico – CNPq.

REFERÊNCIAS BIBLIOGRÁFICAS

- Alhajjaseen, W. K. M., e Iryo-Asano, M. (2017) Studying critical pedestrian behavioral changes for the safety assessment at signalized crosswalks. *Safety Science*, 91, 351–360. doi:10.1016/j.ssci.2016.09.002
- Alver, Y., Onelcin, P., Cicekli, A., e Abdel-Aty, M. (2021) Evaluation of pedestrian critical gap and crossing speed at midblock crossing using image processing. *Accident Analysis and Prevention*, 156(April), 106127. doi:10.1016/j.aap.2021.106127
- Bochkovski, A., Wang, C.-Y., e Liao, H.-Y. M. (2020) YOLOv4: Optimal Speed and Accuracy of Object Detection. Obtido de <http://arxiv.org/abs/2004.10934>
- Forgy, E. (1965) Cluster Analysis of Multivariate Data: Efficiency versus Interpretability of Classifications. *Biometrics*, 21, 768–780.
- Jacobsen, A. C. (2011) *Microsimulação da travessia de pedestres*. Universidade Federal do Rio Grande do Sul.
- Li, Q., Wang, Z., Yang, J., e Wang, J. (2005) Pedestrian delay estimation at signalized intersections in developing cities. *Transportation Research Part A: Policy and Practice*, 39(1), 61–73. doi:10.1016/j.tra.2004.11.002
- Lipovac, K., Vujanic, M., Maric, B., e Nesic, M. (2013) Pedestrian behavior at signalized pedestrian crossings. *Journal of Transportation Engineering*, 139(2), 165–172. doi:10.1061/(ASCE)TE.1943-5436.0000491
- Liu, R., Silva, J.P., e Seco, A.J. A bi-modal micro-simulation tool for the assessment of pedestrian delays and traffic management. *9th International Association of Travel Behavior Research Conference*, Gold Coast, Australia: 2000.
- Ma, W., Liao, D., Liu, Y., e Lo, H. K. (2015) Optimization of pedestrian phase patterns and signal timings for isolated intersection. *Transportation Research Part C: Emerging Technologies*, 58, 502–514. doi:10.1016/j.trc.2014.08.023

- Malki, A. Al, Rizk, M. M., El-Shorbagy, M. A., e Mousa, A. A. (2016) Hybrid Genetic Algorithm with K-Means for Clustering Problems. *Open Journal of Optimization*, 05(02), 71–83. doi:10.4236/ojop.2016.52009
- Martín, L. E., Bandeira, T. P., Pinto, L. D. G., e Castro Neto, M. M. de (2019) Atraso de pedestres em travessias semaforizadas: uma comparação entre as modelagens pelo HCM e pelo microssimulador VISSIM. *Transportes*, 27(1), 128–140. doi:10.14295/transportes.v27i1.1581
- Mesquita, K. G. de A., Castro Junior, F. A. B. de, e Cunha, M. G. de H. (2020) Caracterização de pedestres obedientes e oportunistas em travessias semaforizadas de Fortaleza. Associação Nacional de Pesquisa e Ensino em Transportes (Ed), *34º Congresso de Pesquisa e Ensino em Transporte da ANPET* (p. 2474–2485). Anais [...], 100% Digital.
- Mohamad Nor, S. N., David Daniel, B., Hamidun, R., Al Bargi, W. A., Rohani, M. M., Prasetijo, J., Aman, M. Y., e Ambak, K. (2017) Analysis of Pedestrian Gap Acceptance and Crossing Decision in Kuala Lumpur. *MATEC Web of Conferences*, 103. doi:10.1051/mateconf/201710308014
- Redmon, J., e Farhadi, A. (2018) YOLOv3: An Incremental Improvement. *arXiv*.
- Roughail, N., Hummer, J., Milazzo, J., e Allen, D. (1998) *Recommended Procedures Chapter 13, “Pedestrian”, of the Highway Capacity Manual*. Report FHWA-RD-98-107, Washington, D.C.
- Suh, W., Henclewood, D., Greenwood, A., Guin, A., Guensler, R., Hunter, M. P., e Fujimoto, R. (2013) Modeling pedestrian crossing activities in an urban environment using microscopic traffic simulation. *Simulation*, 89(2), 213–224. doi:10.1177/0037549712469843
- Tang, L., Liu, Y., Li, J. L., Qi, R., Zheng, S., Chen, B., e Yang, H. (2020) Pedestrian crossing design and analysis for symmetric intersections: Efficiency and safety. *Transportation Research Part A: Policy and Practice*, 142(February), 187–206. doi:10.1016/j.tra.2020.10.012
- The AI Guy. (2020) yolov4-deepsort. *GitHub repository*. GitHub. Obtido de <https://github.com/theAIGuysCode/yolov4-deepsort>
- TRB. (2016) *Highway Capacity Manual 6th Edition*. Washington, DC.
- Wang, C.-Y., Bochkovskiy, A., e Liao, H.-Y. M. (2021) Scaled-YOLOv4: Scaling Cross Stage Partial Network. Obtido de <http://arxiv.org/abs/2011.08036>
- Wang, X., e Tian, Z. (2010) Pedestrian delay at signalized intersections with a two-stage crossing design. *Transportation Research Record*, (2173), 133–138. doi:10.3141/2173-16
- Wojke, N., e Bewley, A. (2018) Deep Cosine Metric Learning for Person Re-identification. *2018 IEEE Winter Conference on Applications of Computer Vision (WACV)* (p. 748–756). IEEE. doi:10.1109/WACV.2018.00087
- Wojke, N., Bewley, A., e Paulus, D. (2017) Simple online and realtime tracking with a deep association metric. *Proceedings - International Conference on Image Processing, ICIP, 2017-Septe*, 3645–3649. doi:10.1109/ICIP.2017.8296962
- Zhang, S., Abdel-Aty, M., Yuan, J., e Li, P. (2020) Prediction of Pedestrian Crossing Intentions at Intersections Based on Long Short-Term Memory Recurrent Neural Network. *Transportation Research Record*, 2674(4), 57–65. doi:10.1177/0361198120912422